

كلية ابن سيرين  
قسم الذكاء الاصطناعي

تعلم الآلة

# Machine Learning

---

المحاضرة الأولى

م/عبد القدوس المصري

## (Introduction to Machine Learning)

❖ من البرمجة الحتمية إلى البرمجة الاحتمالية:

في المستويات الدراسية السابقة، اعتمدتم على البرمجة التقليدية (Deterministic Programming) حيث يقوم المبرمج

بصياغة قواعد صريحة وخوارزمية ثابتة  $f(\mathcal{X})$  لتحويل المدخلات (Data) إلى مخرجات (Outputs).

أما في تعلم الآلة (Machine Learning)، فإننا ننتقل إلى البرمجة الاحتمالية أو الاستقرائية (Inductive) نحن نمتلك

البيانات والنتائج السابقة، ونطلب من الحاسوب استنتاج الدالة التقريبية  $f$  التي تربط بينهما بحيث:

$$\gamma \approx f(\mathcal{X}) + \epsilon$$

حيث  $\epsilon$  يمثل نسبة الخطأ أو الضوضاء (Noise) الطبيعية في البيانات.

# (Introduction to Machine Learning)

٣

• تعريف آرثر سامويل وجيرثي هينتون الفلسفي:

"هو فرع من فروع الذكاء الاصطناعي يمنح أجهزة الحاسوب القدرة على التعلم من البيانات والتجارب السابقة دون أن يتم برمجة هذه الأجهزة بشكل صريح (Explicitly Programmed) لكل خطوة."

❖ لماذا نحتاج تعلم الآلة الآن؟ (المحركات الثلاثة) :

١. انفجار البيانات (Big Data): توليد كميات هائلة من البيانات غير المنظمة (نصوص، صور، فيديو) التي يستحيل صيغ قواعد يدوية لها.
٢. قوة المعالجة (Computing Power): الطفرة الكبيرة في المعالجات الرسومية (GPUs) ومسرعات الذكاء الاصطناعي (TPUs).
٣. تطور الخوارزميات (Algorithmic Advances): تحسين طرق تحسين الدوال (Optimization) وهبوط التدرج العشوائي (Stochastic Gradient Descent).


م/عبدالقُدوس المصري

# ( Machine Learning )

٤

❖ التشرح العميق للأنواع الرئيسية:

لتسهيل استيعاب الأنواع الرئيسية وآليات عملها، نعتد على المخطط الشامل التالي الذي يوضح الفروقات الجوهرية وطرق التجميع والتعلم المعزز:



م/عبد القدوس المصري

# ( Machine Learning )

٥

## ١. التعلم بإشراف (Supervised Learning):

الهدف الرياضي هنا هو تعلم دالة ترسم خريطة من الفضاء  $X$  إلى الفضاء  $\gamma$  بناءً على أزواج تدريبية معلمة ومحددة مسبقاً.....  $(X_1, \gamma_1), (X_2, \gamma_2), \dots$ .

كما يظهر في الربع الأول من المخطط الشامل (Overview of Machine Learning Types)، يتم تزويد النموذج بالبيانات والإجابات الصحيحة معاً ليقوم ببناء النموذج التنبؤي.

أ. مسألة الانحدار (Regression): التنبؤ بقيم مستمرة (مثل أسعار المنازل أو درجات الحرارة).  
النموذج الرياضي الأبسط هو الانحدار الخطي:

$$\gamma = \omega_0 + \omega_1 X_1 + \omega_2 X_2 + \dots$$

حيث يحاول النموذج تعلم الأوزان  $(w)$  لتقليل دالة الخسارة كمتوسط مربعات الخطأ (MSE):

$$\text{MSE} = \frac{1}{\mathcal{M}} \sum_{i=1}^{\mathcal{M}} (\mathbf{y}^{(i)} - \hat{\mathbf{y}}^{(i)})^2$$

ب. مسألة التصنيف (Classification): فصل البيانات إلى فئات منفصلة (مثل تصنيف البريد إلى عادي أو سبام، وتصنيف الصور إلى قطط وكلاب كما هو موضح بالرسم).

# ( MACHINE LEARNING )

٦

## ٢. التعلم بدون إشراف (Unsupervised Learning):

هنا لا توجد تسميات أو إجابات مسبقة ( $Y$ ) المعطيات هي الفضاء  $X$  فقط. الهدف هو اكتشاف الهياكل والأنماط المخفية داخل البيانات.

أ- التجميع (Clustering): تقسيم البيانات إلى مجموعات تشترك في خصائص معينة.

انظر إلى الربع الثاني من الصورة التوضيحية (K-Means Clustering):

١. المرحلة A: يتم اختيار مراكز عشوائية مبدئية (Initial random centroids).

٢. المرحلة B: يتم تخصيص كل نقطة إلى المركز الأقرب لها (Points assigned to the nearest centroid) بناءً على المسافة الإقليدية.

٣. المرحلة C: يتم تحديث أماكن المراكز عبر نقلها إلى وسط المجموعات الجديدة (Centroids updated to the center of their clusters).

٤. المرحلة D: تكرار العملية حتى نصل إلى مجموعات نهائية مستقرة (Final stable clusters).

ب- تقليل الأبعاد (Dimensionality Reduction): لتفادي "لعنة الأبعاد" (Curse of Dimensionality) عندما تزيد الميزات بشكل ضخم وتصبح البيانات متباعدة، نستخدم خوارزميات مثل PCA لضغط الأبعاد مع الحفاظ على التباين.

م/عبد القدوس المصري

## ( MACHINE LEARNING )

٧

### ٣. التعلم المعزز (Reinforcement Learning):

يعتمد على تفاعل العميل الذكي مع بيئته دون بيانات مسبقة.

انظر إلى الربع الثالث من الصورة (Reinforcement Learning Loop):

- يقوم العميل (Agent) باتخاذ إجراء (Action A) بناءً على الحالة الحالية (State S).
- تستجيب البيئة (Environment) عبر تقديم حالة جديدة (State S) ومنح مكافأة موجبة (+1 Reward) إذا كان الفعل صحيحاً، أو عقوبة سالبة (-1 Reward) إذا كان خاطئاً.
- الهدف الرياضي هو تعظيم العائد المستقبلي المخفض عبر سياسة اتخاذ القرار الأمثل.

❖ هندسة البيانات ودورة حياة النظام:

تطبيق تعلم الآلة في المشاريع الفعلية يمر بخط إنتاج متسلسل وواضح (Pipeline):

[جمع البيانات] —> [التنظيف والتحضير] —> [هندسة الميزات] —> [التدريب] —> [التقييم]

# ( MACHINE LEARNING )

٨

## ❖ تنظيف البيانات وتحضيرها (Data Preprocessing):

- معالجة القيم المفقودة: إما بحذف العينات أو تعويضها بالمتوسط الحسابي أو الوسيط.
- الترميز الفئوي (Categorical Encoding): تحويل الكلمات والنصوص إلى أرقام مثل (One-Hot Encoding).
- تطبيع البيانات (Feature Scaling): جعل قيم كل الميزات تقع في نفس النطاق (مثلاً بين ٠ و ١) حتى لا تتأثر الخوارزميات التي تعتمد على المسافات بالفروقات الضخمة بين الوحدات.

## ❖ معضلة الانحياز والتباين (Bias-Variance Tradeoff):

هذا المفهوم هو لب تقييم النماذج هندسياً، ويمكنكم فهمه عبر الرسوم البيانية في الربع الرابع من الصورة التوضيحية (Bias-Variance Tradeoff and Evaluation):

١. الافتقار للملاءمة (Underfitting): يحدث عندما يكون النموذج بسيطاً جداً (تعقيد منخفض). تلاحظ وجود انحياز عال (High Bias) مما يؤدي إلى نسبة خطأ إجمالية مرتفعة في التدريب والاختبار على حد سواء.
٢. الإفراط في الملاءمة (Overfitting): يحدث عندما يصبح النموذج معقداً جداً ويقوم بحفظ البيانات وضوضائها. يظهر الرسم خطأ تدريب منخفض جداً ولكن عند التحقق يرتفع الخطأ بشدة (High Validation Error / High Variance).
٣. النموذج الأمثل (Optimal): هو نقطة الاتزان الحساسة التي تحقق أقل نسبة خطأ إجمالية ممكنة (Lowest Total Error) مع موازنة مثالية بين الانحياز والتباين.